

۱. (۲ نمره) اگر هدف یادگیری بازنمایی (representation) خوب برای کلمات زبان باشد به نحوی که بتوان از آن در تسک‌های مختلف استفاده نمود، از چه داده‌ها یا ویژگی‌هایی می‌توان استفاده کرد؟ (۳ مورد)

۲. (۲ نمره) توضیح دهید که چرا مدل ترنسفورمر برای درک روابط بین کلمات یک جمله به بیشتر از یک لایه نیاز دارد؟ با ذکر یک مثال مشخص در یک تسک این کار را انجام دهید.

۳. (۲ نمره) معماری ترنسفورمر اولین بار برای چه تسکی استفاده شد؟ مهمترین تفاوت آن با معماری‌های موجود در آن زمان در چه بود؟

۴. (۲ نمره) تفاوت معماری encoder-decoder با prefix LM در چیست؟ آیا در نتایجی که T5 گرفت، معماری خاصی برتری داشت؟ شما چه فکر می‌کنید؟

۵. (۴ نمره)

الف) مدل GPT3 با افزایش بسیار زیاد سائز ساخته شد. چه نتایج یا مشاهدات جدید و جالبی از این کار بدست آمد؟
ب) در چه نوع تسک‌هایی این مدل به مشکل جدی برخورد؟ در کارهای بعدی چطور این مساله تا حدی برطرف شد؟

۶. (۲ نمره) تفاوت local attention با fully-connected feed-forward در چیست (دو مورد)؟

۷. (۱/۵ نمره) سه مدل زبانی بزرگ A، B و C پس از آموزش، روی دیتای تست به ترتیب پریکسیته ۵، ۵.۵ و ۴.۵ را کسب کرده‌اند. انتظار دارید کدام مدل کیفیت بهتری بدست آورد؟ توضیح دهید.

۸. (۲ نمره) رضا می‌خواهد به کمک مدل جدید Llama 3 سوالات میان‌ترم درس LLM را حل کند. برای اطمینان از قدرت مدل، او سوالات کوئیزهای درس را به مدل می‌دهد و متوجه می‌شود مدل توانایی چندانی در حل سوالات این درس ندارد. او پس از جستجوی فراوان موفق می‌شود سوالات میان‌ترم و پایان‌ترم ترم‌های گذشته درس NLP دانشگاه تهران را که تا حدی شبیه درس LLM هستند، بدست آورد.

الف) به کمک سوالات بدست آمده، علی چگونه می‌تواند کیفیت مدل را بهبود دهد. (۲ روش را ذکر کنید).

ب) برای هر کدام از راه‌های ذکر شده در قسمت (الف)، دو مزیت و دو عیب را ذکر نمایید.

۹. (۱ نمره) روش LoRA چه تاثیری روی زمان inference دارد؟ توضیح دهید.

۱۰. (۲ نمره) یکی از مشکلات استفاده از روش RAG، محدودیت اندازه context مدل LLM ورودی است. دو راه برای کاهش یا فائق آمدن بر این مشکل ذکر کنید.